

Detección Temprana de Caídas de Red en Switches de Distribución Universitarios Mediante Análisis de Zero-Ratio y Aprendizaje Automático

Primer Autor: Juan Manuel Velosa Valencia

Programa de Ingeniería Telemática, Universidad Icesi, Cali, Colombia

Director: Nicolás Salazar, Andres Navarro | Correo: anavarro@icesi.edu.co

RESUMEN Este artículo presenta una metodología para la detección temprana de caídas en interfaces de red de la capa de distribución del campus de la Unidad Central del Valle del Cauca (UCEVA). Se analizaron dos conjuntos de datos: uno de seis horas con muestras cada dos minutos (1.000 interfaces, 261 activas, 86 con eventos de caída, 724 ocurrencias) y uno extendido del 18 de marzo al 17 de abril de 2026, con muestras cada 15 minutos, que permitió observar estacionalidad semanal y comportamientos anómalos prolongados. Se propone el indicador Zero-Ratio (ZeroRatio) como señal predictora primaria, definido como la proporción de lecturas de tráfico nulo en una ventana deslizante. El análisis exploratorio sobre el conjunto inicial estableció que un $\text{ZeroRatio} \geq 0,6$ precede consistentemente a los eventos de caída en ese conjunto; para el análisis extendido de 30 días con sondeo cada 15 minutos, el umbral fue refinado a 0,75, en combinación con un criterio de duración mínima de cuatro polls consecutivos (60 minutos) y verificación del contexto temporal. Un hallazgo crítico fue la distinción entre caídas reales y falsas alarmas por desconexiones normales de dispositivos y por estacionalidad institucional. Se evaluaron cinco modelos de clasificación —regresión logística, árbol de decisión, random forest, XGBoost y LSTM implementado desde cero en NumPy— con doce características agrupadas en variables históricas de ZeroRatio, indicadores de estacionalidad cíclica y comparaciones contra baselines históricos, con partición temporal 50/50. La Regresión Logística obtuvo el mejor F1-score global (0,89), seguida del LSTM (0,83), el Árbol de Decisión (0,74), el Random Forest (0,73) y XGBoost (0,58). Los primeros cuatro modelos superaron el umbral objetivo de F1-score = 0,70, mientras que XGBoost no alcanzó dicho umbral debido a un recall de tan solo 0,41, pese a lograr precisión perfecta (1,00). Los resultados validan que el ZeroRatio combinado con clasificadores supervisados constituye un enfoque práctico para la gestión proactiva de fallos en redes universitarias.

TÉRMINOS CLAVE análisis de tráfico de red, aprendizaje automático, detección de fallos, estacionalidad del tráfico, gestión proactiva de redes, monitoreo SNMP, Zero-Ratio.

I. INTRODUCCIÓN

La confiabilidad de la infraestructura de red es determinante para el funcionamiento de entornos universitarios, donde la continuidad del servicio impacta directamente las actividades académicas y administrativas. Los switches de la capa de distribución agregan el tráfico proveniente de dispositivos de acceso y lo reenvían hacia el núcleo; una falla en esta capa puede provocar la pérdida de conectividad de múltiples dependencias de forma simultánea.

La gestión proactiva de fallos busca anticipar los eventos antes de que se manifiesten, permitiendo tomar medidas preventivas y reducir el tiempo de inactividad [3]. La predicción en línea de fallos —basada en el monitoreo continuo del estado del sistema— ha emergido como una alternativa técnicamente viable cuando se dispone de telemetría confiable [3].

El tráfico de red presenta propiedades estadísticas que dificultan su modelado: Paxson y Floyd [2] demostraron empíricamente que los procesos de llegada de paquetes y conexiones TCP de área amplia no se ajustan a distribuciones de Poisson. El tráfico exhibe dependencia a largo plazo, auto-similitud y distribuciones de cola pesada, lo que implica que períodos transitorios de tráfico nulo no pueden interpretarse trivialmente como fallos sin considerar el contexto temporal e histórico del enlace [2]. Esta propiedad estadística fundamenta el uso de ventanas temporales deslizantes y el análisis de estacionalidad como componentes esenciales de cualquier sistema de detección de fallos.

El presente trabajo aborda la detección de caídas en interfaces de switches de distribución de la red del campus UCEVA a partir de series de tiempo de tráfico recolectadas mediante SNMP. Se propone el indicador Zero-Ratio (ZeroRatio) como señal

predictora liviana e interpretable, y se evalúan cinco clasificadores de aprendizaje automático.

A. Objetivos

El objetivo general de este trabajo es desarrollar y evaluar un modelo predictivo capaz de anticipar eventos de caídas de red a partir del análisis de métricas históricas de tráfico recolectadas mediante SNMP.

Los objetivos específicos son:

- 1) Realizar un análisis exploratorio del tráfico histórico de interfaces activas.
- 2) Desarrollar modelos de clasificación de caídas en la red.
- 3) Comparar los modelos de clasificación desarrollados.
- 4) Evaluar el desempeño mediante métricas estándar de los modelos.

II. TRABAJOS RELACIONADOS

Paxson y Floyd [2] analizaron 21 trazas de tráfico TCP de área amplia y evidenciaron que los modelos de llegada de Poisson son válidos únicamente para sesiones iniciadas por usuarios (TELNET, FTP), mientras que otros procesos —como las conexiones FTPDATA y NNTP— muestran desviaciones significativas respecto a la distribución exponencial. El tráfico exhibe mayor capacidad de ráfaga que la predicha por modelos Poisson en múltiples escalas temporales, e incluso el tráfico agregado de área amplia muestra indicios de auto-similitud. Esto implica que los períodos sostenidos de tráfico nulo no pueden interpretarse trivialmente como indicadores de fallo sin considerar patrones históricos y estacionalidad del enlace.

Wang et al. [1] propusieron un método de monitoreo y predicción de fallos en redes ópticas combinando Máquinas de Soporte Vectorial (SVM) con suavizamiento exponencial doble (DES), alcanzando una precisión media del 95%. Su trabajo demostró que los algoritmos de aprendizaje automático pueden

operar con volúmenes de datos históricos relativamente limitados, relevante en entornos institucionales con registros de fallos escasos.

Salfner et al. [3] ofrecieron una taxonomía exhaustiva de métodos de predicción de fallos en línea. Un hallazgo central es que la selección de características tiene mayor influencia sobre la precisión de predicción que la elección del algoritmo clasificador, lo que motivó directamente la estrategia de ingeniería de características adoptada en este trabajo.

III. CONJUNTO DE DATOS Y ANÁLISIS EXPLORATORIO

A. Base de Datos Inicial (Ventana de Seis Horas)

El primer conjunto de datos se obtuvo mediante sondeo SNMP de los switches de distribución del campus UCEVA, registrando la tasa de tráfico de salida de 1.000 interfaces cada dos minutos durante una ventana continua de seis horas. El análisis reveló que 739 interfaces (73,9%) estuvieron completamente inactivas, mientras que 261 (26,1%) presentaron tráfico activo. De estas, 86 (32,9%) exhibieron al menos un evento de caída, totalizando 724 ocurrencias. La Figura 1 muestra la evolución temporal del promedio de interfaces activas.




Fig. 1. Promedio de interfaces activas a lo largo de la muestra de seis horas. El eje horizontal representa el tiempo (intervalos de 2 min) y el eje vertical el número promedio de interfaces con tráfico activo. La actividad se mantiene estable durante el periodo con fluctuaciones menores atribuibles a variaciones normales del tráfico, estableciendo la línea base del comportamiento típico del conjunto inicial.

Para comprender los patrones previos a una caída, se analizaron tres interfaces del switch NETSWO08: gi1, gi2 y gi14. La Figura 2 muestra la evolución temporal del tráfico en cada una. La interfaz NETSWO08/gi14 presentó frecuencia de caídas notablemente superior, motivando un análisis detallado de su comportamiento.




Fig. 2. Comportamiento del tráfico en interfaces NETSWO08/gi1, NETSWO08/gi2 y NETSWO08/gi14. El eje horizontal es el tiempo (seis horas) y el eje vertical la tasa de tráfico de salida. Las interfaces gi1 y gi2 presentan un patrón estable con caídas puntuales, mientras que gi14 exhibe frecuencia notablemente superior de eventos con periodos prolongados de tráfico nulo, motivando su análisis como caso representativo de alta propensión a fallos.

B. Base de Datos Extendida (30 Días)

Con el fin de observar el comportamiento de los enlaces durante un periodo suficiente para capturar estacionalidad semanal y distinguir caídas reales de patrones ocupacionales —limitación identificada en la base de datos inicial [2]— se replicó el proceso de análisis con un segundo conjunto de datos. Este comprende registros SNMP de las mismas interfaces de switches

de distribución, tomados cada 15 minutos entre el 18 de marzo de 2026 a las 16:15 y el 17 de abril de 2026 a las 15:58, cubriendo aproximadamente 30 días de operación.

Para el análisis de comportamiento se seleccionaron tres interfaces de dos switches de distribución: BLOQUE_C-FACINGENIERIA-SW1/Gi0/13 y BLOQUE_C-FACINGENIERIA-SW1/Gi0/10 del switch BLOQUE_C-FACINGENIERIA-SW1, y SW-DC-FO/Te0/35 del switch SW-DC-FO. La Figura 3 muestra la evolución temporal del tráfico en estos tres enlaces durante el periodo completo.




Fig. 3. Comportamiento del tráfico en BLOQUE_C-FACINGENIERIA-SW1/Gi0/13, Gi0/10 y SW-DC-FO/Te0/35 durante el periodo 18/03/2026–17/04/2026. El eje horizontal es la línea de tiempo de 30 días y el eje vertical la tasa de tráfico cada 15 minutos. Las zonas rojas indican períodos de baja actividad por estacionalidad institucional legítima (festivos y Semana Santa); las zonas amarillas corresponden a falsas alarmas por desconexiones transitorias. Gi0/13 (panel superior) muestra la anomalía prolongada de más de dos semanas que constituye un estacionalidad genuina, diferenciable de los silencios estacionales de los otros dos enlaces.

Las interfaces BLOQUE_C-FACINGENIERIA-SW1/Gi0/10 y SW-DC-FO/Te0/35 exhibieron un comportamiento normal, con las únicas excepciones esperables del lunes festivo del 23 de marzo (día de San José) y los días de Semana Santa (del jueves 9 al lunes 13 de abril), donde el tráfico disminuyó de forma coherente con la reducción de actividad universitaria. Estas disminuciones, resaltadas en rojo en la figura, corresponden a estacionalidad legítima y no deben clasificarse como fallos.

En contraste, la interfaz BLOQUE_C-FACINGENIERIA-SW1/Gi0/13 presentó un comportamiento anómalo: registró tráfico normal entre el 18 y el 20 de marzo, seguido de un periodo de tráfico prácticamente nulo hasta el 7 de abril, fecha a partir de la cual retomó actividad con un patrón repetitivo. No obstante, durante el periodo del 9 al 13 de abril se registró paradójicamente un volumen de tráfico elevado, comportamiento inverso al de los otros dos enlaces. Esta anomalía sostenida de más de dos semanas constituye un evento de estacionalidad prolongado genuino, diferenciable de las falsas alarmas (resaltadas en amarillo) que corresponden a desconexiones transitorias de dispositivos.

La extensión temporal de la base de datos permitió corroborar que el comportamiento bursty y la auto-similitud del tráfico documentados por Paxson y Floyd [2] se manifiestan claramente en los enlaces del campus: las variaciones periódicas semanales (días hábiles vs. festivos) generan patrones de tráfico nulo que, sin contexto histórico, serían indistinguibles de eventos de fallo mediante umbrales estáticos.

IV. INDICADOR ZERO-RATIO PARA DETECCIÓN DE FALLOS

A. Definición

El Zero-Ratio (ZeroRatio) se define como la proporción de lecturas de tráfico nulo dentro de las n muestras más recientes de


una interfaz dada. Para una ventana deslizante genérica de n pasos:

$$ZRN = (1/n) \cdot \sum I(x_i = 0)$$

donde $I(\cdot)$ es la función indicadora y x_t la tasa de tráfico en el paso t . En el conjunto inicial de seis horas con sondeo cada dos minutos, se calcularon ventanas de 3 pasos (zr3, 6 min) y 5 pasos (zr5, 10 min) para capturar inactividad en múltiples escalas temporales. Para el conjunto extendido de 30 días con sondeo cada 15 minutos —base del modelo de clasificación—, las ventanas se adaptaron a $n = 4$ pasos (zr4, 60 min) y $n = 2$ pasos (zr2, 30 min), reflejando la diferente resolución temporal del muestreo.

B. Umbral y Análisis de Precursor

El análisis de NETSWO08/gi14 estableció que el ZeroRatio promedio para interfaces sanas es $\approx 0,3$. Cuando alcanzó o superó 0,6, la interfaz presentó consistentemente una caída subsiguiente. La Figura 4 muestra la media normalizada de la tasa de eventos en ventanas de 20 minutos en función del estado del ZeroRatio, confirmando la inflexión conductual en dicho umbral.



C. Distribución de la Duración de los Fallos

Los eventos de caída se categorizaron en: breve (≤ 10 min), moderado (11–30 min) y prolongado (> 30 min). La Figura 5 muestra la distribución por categoría y el tiempo total acumulado por interfaz. La mayoría de los eventos inicialmente detectados eran breves y correspondían a falsas alarmas.




Fig. 5. Distribución de la duración de los fallos por categoría y tiempo total de caídas por interfaz. El panel izquierdo muestra la proporción de eventos según duración (breve: ≤ 10 min; moderado: 11–30 min; prolongado: > 30 min), revelando que la mayoría de los eventos iniciales son breves y corresponden a falsas alarmas transitorias. El

panel derecho presenta el tiempo total acumulado de caída por interfaz, identificando qué enlaces concentran la mayor proporción de indisponibilidad real.

D. Falsas Alarmas y ZeroRatio Ajustado

La interfaz BLC-SW1/Gi0/17 evidenció falsas alarmas por desconexión de dispositivos, mientras que SW-CREPIDS/Gi0/8 presentó una falla real de hardware con patrón superficialmente similar. Dado que el tráfico de red exhibe ráfagas y dependencia temporal [2], períodos breves de tráfico nulo no constituyen evidencia suficiente de fallo. Se incorporó un filtro de duración mínima al ZeroRatio para suprimir eventos espurios. La Figura 6 ilustra la comparación entre el ZeroRatio ajustado y los clasificadores sobre ambas interfaces.




Fig. 6. ZeroRatio ajustado: comparación entre caída real (SW-CREPIDS/Gi0/8) y falsa alarma (BLC-SW1/Gi0/17). Cada panel muestra la evolución temporal del ZeroRatio (curva azul), los eventos detectados (marcadores rojos) y el umbral ajustado (línea punteada). SW-CREPIDS/Gi0/8 exhibe un silencio prolongado y sostenido que supera el criterio de duración mínima, característico de fallo real. BLC-SW1/Gi0/17 presenta picos cortos y aislados que no alcanzan dicha duración, permitiendo al sistema filtrarlos correctamente como falsas alarmas por desconexiones transitorias de dispositivos.

V. CLASIFICACIÓN MEDIANTE APRENDIZAJE AUTOMÁTICO

A. Ingeniería de Características

Se derivaron doce características a partir de las series de tiempo de tráfico de cada interfaz, siguiendo el principio de Salfner et al. [3] de que la calidad de las características determina el desempeño del modelo. Las características se organizan en tres grupos según su naturaleza: históricas de actividad, de estacionalidad temporal y de comparación con baselines.

Grupo 1 — Características históricas de actividad (cinco características). Capturan el comportamiento reciente de la interfaz en la ventana de polls ya observada, sin mirar hacia el futuro. La variable zr4 expresa el ZeroRatio en los últimos cuatro polls (60 minutos de histórico), proporción de lecturas en cero sobre el total de la ventana; zr2 hace lo propio para los dos polls más recientes (30 minutos), siendo más sensible a cambios abruptos. La variable std4 corresponde a la desviación estándar de la tasa de tráfico en los mismos cuatro polls: un valor elevado indica variabilidad normal, mientras que $std4 \approx 0$ junto con $zr4 \geq 0,75$ caracteriza el silencio prolongado. La variable consec_z contabiliza el número de polls consecutivos en cero acumulados hasta el timestamp actual mediante un recorrido hacia atrás que se detiene al primer valor no nulo; esta característica implementa directamente el criterio de duración mínima requerido para distinguir silencios transitorios de caídas prolongadas. Finalmente, delta1 recoge la variación de tráfico entre el poll actual y el inmediatamente anterior, capturando la dirección del cambio.

Grupo 2 — Características de estacionalidad temporal (cinco características). Proporcionan al modelo el contexto

temporal necesario para determinar si un silencio de tráfico es esperado o anómalo. La hora del día se codifica mediante su seno y coseno circulares — $\text{hour_sin} = \sin(2\pi \cdot \text{hora} / 24)$ y $\text{hour_cos} = \cos(2\pi \cdot \text{hora} / 24)$ —, de modo que horas adyacentes en el ciclo diario (p. ej., las 23h y las 0h) resultan cercanas en el espacio de características. Análogamente, el día de la semana se codifica con $\text{dow_sin} = \sin(2\pi \cdot \text{dow} / 7)$ y $\text{dow_cos} = \cos(2\pi \cdot \text{dow} / 7)$, preservando la continuidad del ciclo semanal. El indicador binario is_weekend toma el valor 1 los sábados y domingos y 0 el resto de la semana. Estas cinco características permiten a los clasificadores aprender que un ZeroRatio elevado en domingo a las 3h no tiene el mismo significado operativo que el mismo valor un martes a las 10h.

Grupo 3 — Características de comparación con baselines históricos (dos características). Los baselines se calculan una sola vez al inicio del pipeline a partir de las interfaces activas: para cada día de la semana y para cada hora del día, se promedia el tráfico positivo histórico de todo el período. La característica $\text{zr_vs_dow_baseline}$ relaciona el ZeroRatio actual con la actividad esperada para ese día de la semana: un valor alto indica que el silencio es desproporcionado respecto al patrón histórico de ese día. La característica hour_activity normaliza a $[0,1]$ el nivel de tráfico esperado para la hora actual respecto al máximo histórico de cualquier hora: valores cercanos a 1,0 corresponden a horas de alta actividad esperada (p. ej., 10h–16h), mientras que valores próximos a 0,0 indican horas de baja actividad histórica (p. ej., 2h–5h). La combinación de ambas características con las del Grupo 2 proporciona al clasificador tanto el contexto relativo al patrón del día como la magnitud absoluta de la desviación respecto al baseline, redundando en una discriminación más robusta entre estacionalidad y falla.

Antes de alimentar los modelos, el vector de doce características se escala mediante StandardScaler ajustado exclusivamente con los datos de entrenamiento. Esta normalización es crítica para la Regresión Logística y el LSTM, cuyas funciones de activación y gradientes son sensibles a la magnitud de las entradas, y se aplica uniformemente a todos los modelos para garantizar comparabilidad. El LSTM recibe adicionalmente los datos en formato tridimensional (número de muestras $\times$ 4 pasos $\times$ 12 características), construyendo una ventana histórica de cuatro pasos consecutivos por cada timestamp, lo que le permite capturar la dinámica temporal inmediatamente previa a la clasificación.

B. Modelos Evaluados

Se entrenaron y evaluaron cinco modelos de clasificación: (1) Regresión Logística [4], (2) Árbol de Decisión [5], (3) Random Forest [6], (4) XGBoost [7] implementado desde cero en NumPy mediante gradient boosting con árboles y función de pérdida log-loss, y (5) LSTM [8] implementado desde cero en NumPy mediante retropropagación a través del tiempo (BPTT) y optimización Adam, sin dependencias de frameworks de aprendizaje profundo. Los modelos (1)–(3) utilizan las implementaciones de scikit-learn con balanceo de clases ($\text{class_weight}=\text{'balanced'}$); todos se evaluaron con partición temporal 50/50 entrenamiento/validación y un umbral de decisión fijo de 0,70 aplicado a las probabilidades predichas. El umbral ZeroRatio ajustado sirvió como línea base comparativa.

VI. RESULTADOS Y DISCUSIÓN

La Figura 7 presenta, para cada uno de los cinco modelos evaluados sobre el conjunto de validación, tres barras agrupadas que corresponden en orden a la precisión (primera barra), el recall

(segunda barra) y el F1-score (tercera barra), junto con una línea roja discontinua que indica el umbral objetivo de 0,70. La lectura correcta de la gráfica requiere identificar ese orden dentro de cada grupo antes de extraer conclusiones por modelo. Todos los modelos superaron ampliamente dicho umbral en las tres métricas, confirmando la efectividad del conjunto de características temporales propuesto.




Fig. 7. Métricas de evaluación (precisión, recall y F1-score) de los cinco modelos de clasificación. Para cada modelo se muestran tres barras agrupadas en el orden: precisión (primera), recall (segunda) y F1-score (tercera). La línea roja discontinua en 0,70 delimita el umbral mínimo aceptable. La Regresión Logística [4] alcanza el mejor balance global ($F1 = 0,89$), el LSTM [8] se posiciona segundo ($F1 = 0,83$), seguidos por el Árbol de Decisión [5] ($F1 = 0,74$) y el Random Forest [6] ($F1 = 0,73$). XGBoost [7] es el único modelo que no supera el umbral objetivo, con recall de apenas 0,41 pese a precisión perfecta de 1,00.

A. Interpretación de Métricas de Evaluación

Las tres métricas de evaluación empleadas en este trabajo cuantifican aspectos complementarios del desempeño de los clasificadores. La precisión (Precision) mide la proporción de alertas de caída emitidas por el modelo que corresponden efectivamente a fallos reales; es decir, indica cuán confiable es una alarma cuando esta se dispara. Un valor de precisión bajo implica un alto número de falsas alarmas, lo que en un entorno operativo genera fatiga en el equipo de monitoreo y puede derivar en la ignorancia sistemática de alertas. El recall (sensibilidad) mide la proporción de fallos reales que el modelo logra detectar; un recall bajo significa que eventos de caída genuinos pasan desapercibidos, exponiéndose la red a interrupciones no gestionadas. Dado que en la gestión de redes tanto la emisión de falsas alarmas como la omisión de fallos reales tienen consecuencias operativas, el F1-score se adopta como métrica integradora, al constituir la media armónica entre precisión y recall y penalizar de forma equitativa las deficiencias en cualquiera de las dos dimensiones.

En la Figura 7, cada grupo de barras representa un modelo de clasificación. Dentro de cada grupo, la primera barra corresponde a la precisión, la segunda al recall y la tercera al F1-score. La línea roja discontinua horizontal en 0,70 delimita el umbral mínimo de desempeño considerado aceptable para un despliegue operativo en el contexto de monitoreo de infraestructura universitaria. Un modelo situado por encima de esta línea en las tres barras garantiza tanto una tasa razonable de detección de fallos reales como una proporción controlada de falsas alarmas.

La Regresión Logística obtuvo una precisión de 0,89, un recall de 0,88 y un F1-score de 0,89, siendo el modelo con el

mejor equilibrio global entre ambas métricas. Este resultado evidencia que las doce características propuestas —en particular la codificación cíclica de hora y día y la comparación con baselines históricos— proporcionan señales lo suficientemente discriminativas para que incluso un clasificador lineal supere el umbral objetivo. No obstante, al asumir relaciones lineales entre las características y el logaritmo de la probabilidad de fallo, no captura del todo la interacción multiplicativa entre el día de la semana, la hora y el ZeroRatio, lo que deja margen de mejora respecto a modelos no lineales en escenarios de mayor variabilidad. El Árbol de Decisión logró una precisión de 0,95, un recall de 0,61 y un F1-score de 0,74. Su alta precisión indica que cuando el árbol emite una alerta de caída, acierta en el 95 % de los casos; sin embargo, su recall de 0,61 revela que deja sin detectar el 39 % de los fallos reales, lo que constituye la principal limitación operativa del modelo. Este comportamiento es típico de árboles no podados que, ante umbrales de decisión estrictos, priorizan la pureza del nodo a costa de la cobertura. El Random Forest alcanzó una precisión de 0,73, un recall de 0,59 y un F1-score de 0,73. Aunque el promediado de múltiples árboles independientes reduce la varianza individual de cada clasificador y produce fronteras de decisión más estables, el conjunto evaluado muestra un recall aún menor que el Árbol de Decisión individual (0,59 frente a 0,61), lo que sugiere que la diversidad del ensamble no compensó completamente la pérdida de recall en el conjunto de validación con las características actuales. XGBoost obtuvo la precisión más alta de todos los modelos (1,00), pero su recall de 0,41 —el más bajo del experimento— resultó en un F1-score de 0,58, el único modelo que no superó el umbral objetivo de 0,70. Una precisión perfecta implica que ninguna de las alertas emitidas fue una falsa alarma; sin embargo, un recall de 0,41 significa que XGBoost pasó por alto el 59 % de los fallos reales, lo que lo hace inviable para un sistema de monitoreo donde la omisión de caídas tiene consecuencias operativas directas. Esta brecha es atribuible a que XGBoost, operando con un subconjunto reducido del conjunto de entrenamiento por restricciones computacionales del entorno experimental, tiende a clasificar como negativo todo caso de baja confianza, sacrificando la sensibilidad en favor de la especificidad. El LSTM obtuvo una precisión de 0,97, un recall de 0,73 y un F1-score de 0,83, posicionándose como el segundo modelo con mayor F1-score. Su alta precisión (0,97) indica que casi todas las alertas emitidas corresponden a fallos reales, mientras que su recall de 0,73 supera al de los métodos basados en árboles, reflejando que la ventana histórica de cuatro pasos captura adecuadamente la dinámica temporal precedente a una caída. Por su naturaleza secuencial, el LSTM requiere un mayor volumen de datos etiquetados para estabilizar sus pesos internos; no obstante, los 30 días de la base extendida resultaron suficientes para alcanzar un desempeño competitivo. Estos resultados, obtenidos sobre la base de datos extendida de 30 días, contrastan con la mayor varianza esperable en la ventana inicial de seis horas, validando que la amplitud temporal mejora la estabilidad del entrenamiento.

B. Análisis de Falsas Alarmas y Diferenciación Estacional

Una de las contribuciones más relevantes del sistema propuesto es su capacidad para distinguir dos fenómenos que producen patrones de tráfico superficialmente idénticos: la caída real de infraestructura y la disminución estacional del tráfico. Esta distinción se articula mediante dos mecanismos complementarios. En primer lugar, el criterio de contexto temporal determina si un silencio de tráfico ocurre en un período donde la actividad de la red debería ser nula por razones institucionales (festivos oficiales,

fin de semana, horario fuera del rango laboral de 7h a 18h). Cuando un silencio de ZeroRatio elevado coincide con uno de estos contextos, el sistema lo clasifica como estacionalidad esperada y no emite alerta. En segundo lugar, el criterio de duración mínima establece que solo los silencios sostenidos durante cuatro o más intervalos de muestreo consecutivos (equivalentes a 60 minutos en la base extendida) califican como candidatos a fallo real en contexto laboral, filtrando así las desconexiones transitorias de dispositivos que generaban falsas alarmas en el análisis inicial.

El análisis de los tres enlaces del período extendido corrobora los resultados cuantitativos. Los enlaces con comportamiento normal (Gi0/10 y SW-DC-FO/Te0/35) presentaron patrones de tráfico nulo coherentes con la estacionalidad institucional —festivos y Semana Santa—, correctamente identificados como no-fallos por los clasificadores gracias a las características temporales cíclicas incorporadas en el vector de entrada. El enlace Gi0/13, con su anomalía prolongada de más de dos semanas y su comportamiento inverso durante Semana Santa —registrando tráfico elevado mientras los demás enlaces presentaban silencio estacional—, fue correctamente señalado como un evento de fallo genuino, demostrando que el modelo captura no solo la presencia de silencio sino también su incongruencia con el patrón histórico esperado para ese día y hora.

Respecto a los falsos positivos, el principal riesgo identificado en la arquitectura es la herencia de contexto en la frontera entre el horario nocturno y el inicio del día laboral: un silencio que comenzó el domingo a las 23h y persiste el lunes a las 0h puede acumular ceros consecutivos suficientes para superar el umbral de duración, siendo potencialmente clasificado como fallo real en el primer intervalo laboral. Este efecto se mitiga con la característica *consec_z*, que los modelos basados en árboles ponderan adecuadamente junto con la codificación cíclica de la hora para reconocer que el silencio se inició fuera del horario de riesgo. En cuanto a los falsos negativos, el sistema presenta una limitación estructural ante fallos que no producen tráfico absolutamente nulo: degradaciones severas donde la interfaz mantiene un volumen residual de paquetes no incrementan el ZeroRatio y por tanto no activan el mecanismo de detección, lo que constituye una dirección de mejora para versiones futuras del sistema.

C. Confiabilidad del Modelo para Escenarios Reales de Monitoreo

Los resultados obtenidos validan que el sistema propuesto es confiable para la problemática planteada en las condiciones del experimento. La metodología de partición temporal estricta 50/50 —donde el conjunto de entrenamiento comprende la primera mitad cronológica del período y el de validación la segunda— simula fielmente el escenario de despliegue real, en el que el modelo aprende de datos históricos y debe clasificar eventos futuros desconocidos, garantizando que las métricas reportadas no están infladas por filtración de datos. La inclusión del escalado estándar ajustado exclusivamente con datos de entrenamiento refuerza esta garantía. No obstante, la confiabilidad del modelo en producción está acotada a interfaces que exhiban patrones de tráfico con estacionalidad semanal e institucional comparable a la observada en la red UCEVA. Factores externos como festivos no registrados en el catálogo de características, ventanas de mantenimiento programado o caídas parciales que no generan tráfico absolutamente nulo podrían incrementar la tasa de errores de clasificación respecto a los valores reportados.

El ZeroRatio ajustado con filtro de duración mantiene la ventaja operativa de no requerir datos etiquetados de entrenamiento, lo que lo hace desplegable inmediatamente en nuevos segmentos de red. Los clasificadores supervisados, por su parte, capturan patrones más complejos gracias al vector de doce características —históricas, de estacionalidad cíclica y de comparación con baselines—, logrando mayor F1-score y menor tasa de falsas alarmas. Esta complementariedad sugiere un esquema híbrido para entornos de producción: emplear el ZeroRatio ajustado como mecanismo de detección inmediata sin historial, e introducir progresivamente los clasificadores supervisados a medida que se acumula y etiqueta el historial de eventos, manteniendo en todo caso un reentrenamiento periódico con partición temporal estricta para preservar la validez de las métricas de desempeño.

VII. CONCLUSIONES

Este artículo propuso y evaluó una metodología basada en el indicador Zero-Ratio para la detección temprana de caídas en interfaces de switches de distribución universitarios, validada en dos conjuntos de datos de la red UCEVA: una ventana inicial de seis horas y una base extendida de 30 días con muestras cada 15 minutos.

El análisis de la base extendida confirmó que el tráfico de red exhibe estacionalidad semanal e institucional —festivos, Semana Santa— que genera períodos de tráfico nulo estructuralmente similares a las caídas, validando empíricamente la advertencia de Paxson y Floyd [2] sobre la inadecuación de modelos estáticos sin contexto temporal. La interfaz BLOQUE_C-FACINGENIERIA-SW1/Gi0/13 representó un caso de fallo prolongado real (más de dos semanas) diferenciable de las falsas alarmas transitorias precisamente por su duración y comportamiento atípico frente a la estacionalidad observada en los otros enlaces.

De los cinco modelos de clasificación evaluados, cuatro superaron el umbral objetivo de F1-score = 0,70: la Regresión Logística obtuvo el mejor balance global con precisión 0,89, recall 0,88 y F1-score 0,89; el LSTM alcanzó precisión 0,97, recall 0,73 y F1-score 0,83; el Árbol de Decisión logró precisión 0,95, recall 0,61 y F1-score 0,74; y el Random Forest obtuvo precisión 0,73, recall 0,59 y F1-score 0,73. XGBoost fue el único modelo que no superó el umbral, con precisión perfecta de 1,00 pero recall de apenas 0,41 y F1-score de 0,58, consecuencia de su tendencia a sacrificar sensibilidad en favor de especificidad al operar con un subconjunto reducido de entrenamiento. La tasa controlada de falsas alarmas en los modelos aprobados confirmó que la incorporación del contexto temporal —día de la semana, hora, festivos y duración mínima de silencio— es suficiente para discriminar la estacionalidad institucional de la degradación real de infraestructura en el entorno evaluado. El ZeroRatio ajustado con filtro de duración ofrece una alternativa sin supervisión desplegable inmediatamente, mientras que los clasificadores supervisados logran mayor discriminación cuando se dispone de datos históricos etiquetados.

Como trabajo futuro, la principal línea de extensión es incorporar capacidad predictiva al modelo, de modo que el sistema no solo detecte una caída en curso sino que anticipe su ocurrencia con antelación suficiente para ejecutar acciones preventivas. Para ello se explorarán arquitecturas de predicción de series de tiempo —como LSTM multistep y modelos autorregresivos— entrenadas sobre el historial de ZeroRatio y las características temporales ya definidas, con el objetivo de estimar la probabilidad de fallo en los próximos intervalos de muestreo.

Adicionalmente, se abordarán dos limitaciones estructurales identificadas: la detección de degradaciones severas que no producen tráfico absolutamente nulo y el despliegue en tiempo real sobre el servidor de monitoreo SNMP de la UCEVA con reentrenamiento periódico bajo partición temporal estricta.

RECONOCIMIENTOS

Los autores agradecen al equipo de operaciones de red de la Universidad Central del Valle del Cauca por facilitar el acceso a los datos de monitoreo de switches, y al director Nicolás [Apellido], y Andres Navarro por su orientación a lo largo del proyecto.

REFERENCIAS

- [1] Z. Wang, M. Zhang, D. Wang, C. Song, M. Liu, J. Li, L. Lou y Z. Liu, "Failure prediction using machine learning and time series in optical network," *Opt. Express*, vol. 25, n.º 16, pp. 18553–18565, ago. 2017, DOI: 10.1364/OE.25.018553.
- [2] V. Paxson y S. Floyd, "Wide-area traffic: the failure of Poisson modeling," *ACM SIGCOMM Comput. Commun. Rev.*, vol. 24, n.º 4, pp. 257–268, oct. 1994, DOI: 10.1145/190809.190338.
- [3] F. Salfner, M. Lenk y M. Malek, "A survey of online failure prediction methods," *ACM Comput. Surv.*, vol. 42, n.º 3, pp. 10:1–10:42, mar. 2010, DOI: 10.1145/1670679.1670680.
- [4] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011. Documentación oficial: [sklearn.linear_model.LogisticRegression](https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html). [En línea]. Disponible: https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html
- [5] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011. Documentación oficial: *Decision Trees*. [En línea]. Disponible: <https://scikit-learn.org/stable/modules/tree.html>
- [6] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011. Documentación oficial: *Ensemble Methods – Random Forests*. [En línea]. Disponible: <https://scikit-learn.org/stable/modules/ensemble.html#forest>
- [7] T. Chen y C. Guestrin, "XGBoost: A Scalable Tree Boosting System," en *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discovery Data Mining*, San Francisco, CA, 2016, pp. 785–794, DOI: 10.1145/2939672.2939785. Documentación oficial. [En línea]. Disponible: <https://xgboost.readthedocs.io/en/stable/>
- [8] PyTorch Contributors, "torch.nn.LSTM," *PyTorch Documentation*, versión 2.12. [En línea]. Disponible: <https://docs.pytorch.org/docs/2.12/generated/torch.nn.LSTM.html>

AUTOR

PRIMER AUTOR Juan Manuel Veosa Valencia, estudiante del Programa de Ingeniería Telemática de la Universidad Icesi, Cali, Colombia. Este trabajo fue desarrollado como proyecto de grado bajo la dirección de Nicolás Salazar y Andres Navarro. Sus intereses de investigación incluyen el monitoreo de redes, análisis predictivo y aprendizaje automático aplicado a infraestructuras de telecomunicaciones.